

Stratégies de Décodage pour la Génération de Texte Ouverte

Formalisation, Implémentation et Analyse d'une Approche Hybride ϵ -Greedy

Auteurs :

Léa Ludet · Raykesh Ravirooban

Sous la supervision de :

TLIG Ghassen

Projet Final NLP

ESEO - Option DAIA

19 janvier 2026

Résumé

Ce document technique présente une étude comparative approfondie des algorithmes de décodage pour les Grands Modèles de Langage (LLMs). Nous formalisons le problème de la génération de texte *open-ended* comme un processus de décision séquentiel soumis à un compromis entre cohérence (exploitation) et diversité (exploration).

Nous analysons les limites des méthodes déterministes (Greedy, Beam Search) et stochastiques (Nucleus, Typical Sampling) pour introduire une stratégie hybride : l' **ϵ -Greedy Search**, telle que formalisée par Tlig [1]. Cette méthode, inspirée de l'apprentissage par renforcement, module dynamiquement la stochasticité du générateur.

L'étude intègre également l'utilisation de frameworks modernes tels qu'**Ollama** pour l'inférence de modèles récents (Llama 3.2, Mistral). Les résultats expérimentaux, validés par des métriques de pointe telles que *MAUVE* et la similarité sémantique *SimCSE* sur les corpus Wikitext, BookCorpus et CC-News, démontrent que l'approche proposée offre un compromis optimal, surpassant les *baselines* standards en termes de robustesse face aux boucles de répétition.

Mots-clés : NLP, LLM, Décodage, ϵ -Greedy, MAUVE, Nucleus Sampling, Ollama.

Table des matières

1	Introduction	3
2	Formalisation Mathématique	3
2.1	Le Problème de la Génération Auto-régressive	3
2.2	Stratégies Déterministes	3
2.2.1	Greedy Search	3
2.2.2	Beam Search	3
2.3	Stratégies Stochastiques	4
2.3.1	Nucleus Sampling (Top-p)	4
2.3.2	Typical Sampling	4
2.4	Méthode Proposée : ϵ -Greedy Search	4
3	Implémentation et Frameworks	4
3.1	Architecture Hybride : Hugging Face et Ollama	4
4	Protocole Expérimental et Métriques	4
4.1	Définition des Métriques d'Évaluation	4
5	Algorithmes et Implémentation	5
5.1	Algorithme Hybride ϵ -Greedy	5
5.2	Contrastive Search (Comparaison)	6
6	Résultats Expérimentaux	6
6.1	Analyse de Sensibilité (α et k)	6
6.2	Wikitext-103 (Encyclopédique)	7
6.3	BookCorpus (Narratif)	7
6.4	CC-News (Journalistique)	7
6.5	Comparaison Visuelle des Métriques	8
6.6	Analyse Qualitative	8
7	Conclusion	9
A	Annexes : Manuel Technique	10
A.1	Structure du Projet	10
A.2	Guide de Démarrage	10

1 Introduction

Les modèles de langage auto-régressifs modernes, basés sur l'architecture Transformer [2] tels que GPT-2 [3] ou Llama [11], modélisent la probabilité d'une séquence de mots comme le produit des probabilités conditionnelles de chaque token. Cependant, la qualité du texte généré ne dépend pas uniquement de l'entraînement du modèle (paramètres θ), mais de manière critique de l'algorithme de décodage utilisé pour échantillonner x_t à partir de la distribution $P_\theta(\cdot|\mathbf{x}_{<t})$.

Ce projet s'attaque à la problématique de la "dégénérescence" du texte [4], où les méthodes de maximisation de la vraisemblance (Greedy Search) conduisent à des répétitions monotones, tandis que les méthodes d'échantillonnage pur introduisent des hallucinations sémantiques.

L'objectif est d'implémenter et d'évaluer une stratégie hybride, l' ϵ -Greedy Search proposée par Tlig [1], inspirée des algorithmes de bandits-manchots, et de la comparer aux méthodes de l'état de l'art (Contrastive Search, Nucleus Sampling) sur des corpus variés.

2 Formalisation Mathématique

2.1 Le Problème de la Génération Auto-régressive

Soit $\mathcal{V}$ un vocabulaire de taille $|\mathcal{V}|$. On considère une séquence de tokens $\mathbf{x} = (x_1, x_2, \dots, x_T)$ où $x_t \in \mathcal{V}$. Le modèle de langage estime la probabilité conjointe :

$$P(\mathbf{x}) = \prod_{t=1}^T P(x_t|\mathbf{x}_{<t}) \quad (1)$$

À chaque pas de temps t , le modèle produit un vecteur de logits $\mathbf{z}_t \in \mathbb{R}^{|\mathcal{V}|}$. La distribution de probabilité sur le vocabulaire est obtenue via la fonction softmax avec température τ :

$$P(x_t = v|\mathbf{x}_{<t}) = \frac{\exp(z_{t,v}/\tau)}{\sum_{j \in \mathcal{V}} \exp(z_{t,j}/\tau)} \quad (2)$$

où τ est le paramètre de température (fixé à 1.0 par défaut).

2.2 Stratégies Déterministes

2.2.1 Greedy Search

La recherche gloutonne sélectionne à chaque étape le token maximisant la probabilité locale :

$$x_t = \arg \max_{v \in \mathcal{V}} P(v|\mathbf{x}_{<t}) \quad (3)$$

Bien que maximisant la vraisemblance locale, cette méthode souffre de myopie et tend à générer des boucles infinies (ex : "I don't know. I don't know. I don't know.") [10].

2.2.2 Beam Search

Le Beam Search maintient un ensemble $\mathcal{B}_t$ de k hypothèses (faisceaux) pour maximiser la vraisemblance globale approximée. Bien qu'efficace pour la traduction (tâche fermée), il produit des textes génériques et peu "humains" en génération ouverte.

2.3 Stratégies Stochastiques

Pour introduire de la diversité, on échantillonne $x_t \sim P(\cdot|\mathbf{x}_{<t})$.

2.3.1 Nucleus Sampling (Top-p)

Proposé par Holtzman et al. [4], cette méthode tronque la queue de distribution (long tail). On définit le plus petit sous-ensemble $V^{(p)} \subset \mathcal{V}$ tel que :

$$\sum_{v \in V^{(p)}} P(v|\mathbf{x}_{<t}) \geq p \quad (4)$$

La distribution est ensuite renormalisée sur $V^{(p)}$ avant échantillonnage. Cela évite de sélectionner des tokens syntaxiquement corrects mais sémantiquement improbables.

2.3.2 Typical Sampling

Cette méthode [9] contraint l'échantillonnage aux tokens dont la probabilité est proche de l'entropie conditionnelle $H(P(\cdot|\mathbf{x}_{<t}))$, favorisant un contenu informatif (ni trop évident, ni trop surprenant).

2.4 Méthode Proposée : ϵ -Greedy Search

Inspirée par le compromis exploration-exploitation en Reinforcement Learning et formalisée pour la génération de texte par Tlig [1], notre approche hybride introduit un paramètre de contrôle α (équivalent à $1 - \epsilon$). Soit $u \sim \mathcal{U}[0, 1]$. La règle de décision est :

$$x_t = \begin{cases} \arg \max_{v \in \mathcal{V}} P(v|\mathbf{x}_{<t}) & \text{si } u < \alpha \quad (\text{Exploitation}) \\ \text{Sample}(\text{Top}_k(P(\cdot|\mathbf{x}_{<t}))) & \text{sinon} \quad (\text{Exploration}) \end{cases} \quad (5)$$

3 Implémentation et Frameworks

3.1 Architecture Hybride : Hugging Face et Ollama

Notre implémentation repose sur une architecture modulaire permettant de comparer des modèles historiques (GPT-2 via `transformers`) et des modèles SOTA (State-of-the-Art) quantifiés.

Nous avons intégré **Ollama**, un framework permettant l'exécution locale de LLMs optimisés. Cela nous permet d'étendre l'analyse de nos stratégies de décodage à des modèles comme `mistral-7b` et `llama-3.2` sans nécessiter de ressources GPU massives. L'interaction se fait via une interface API REST locale, où nous interceptons les logits ou les tokens générés pour appliquer nos contraintes de décodage personnalisées (ϵ -Greedy).

4 Protocole Expérimental et Métriques

4.1 Définition des Métriques d'Évaluation

Une évaluation multidimensionnelle est nécessaire pour capturer les nuances de la génération de texte, comme suggéré par Zhang et al. [5].

1. MAUVE (Distributionnelle) : Proposée par Pillutla et al. [6], MAUVE mesure la divergence entre la distribution du texte généré et celle du texte humain. Elle utilise des plongements (embeddings) quantifiés pour calculer une approximation de la divergence de Kullback-Leibler.

- *Interprétation* : Score entre 0 et 100. Plus c'est haut, plus le texte est indiscernable d'un texte humain.

2. Diversité (n-gram repetition) : Mesure la "fraîcheur" du texte en calculant le taux d'unicité des n-grammes.

$$\text{Div}_n = \frac{|\text{unique n-grams}|}{|\text{total n-grams}|} \times 100 \quad (6)$$

Une diversité proche de 100% est souhaitable, mais attention : une diversité parfaite peut aussi signifier un texte incohérent (suite de mots aléatoires).

3. Cohérence (Likelihood & Semantic) : Nous distinguons deux types de cohérence :

- **Coh_Like (Vraisemblance) :** Évaluée par un modèle externe (OPT-125m ou OPT-2.7b). C'est la log-vraisemblance moyenne du texte généré selon ce modèle "juge". Plus le score est proche de 0 (donc moins négatif), plus le texte est grammaticalement probable.
- **Coh_Sem (SimCSE) :** Utilise un modèle de similarité sémantique contrastive (SimCSE) pour calculer la similarité cosinus entre le *prompt* et la *génération*. Un score élevé indique que le modèle reste dans le sujet.

5 Algorithmes et Implémentation

Les expériences ont été réalisées en Python avec PyTorch et la bibliothèque Transformers de Hugging Face.

5.1 Algorithme Hybride ϵ -Greedy

L'algorithme ci-dessous détaille la logique d'implémentation. Le filtrage Top-k est appliqué lors de la phase d'exploration pour éviter l'échantillonnage de tokens aberrants.

Algorithm 1 Génération ϵ -Greedy

```
1: Entrée : Modèle  $\mathcal{M}$ , Préfixe  $x_{<t}$ , Seuil  $\alpha$ , Filtre  $k$ , Longueur  $L$ 
2: for  $i = 1$  to  $L$  do
3:    $\mathbf{z}_t \leftarrow \mathcal{M}(x_{<t})$  ▷ Logits
4:    $\mathbf{p} \leftarrow \text{softmax}(\mathbf{z}_t)$ 
5:    $u \leftarrow \text{random}(0, 1)$ 
6:   if  $u < \alpha$  then ▷ Phase Exploitation
7:      $x_t \leftarrow \arg \max(\mathbf{p})$ 
8:   else ▷ Phase Exploration
9:      $V_k \leftarrow \text{top\_k\_indices}(\mathbf{p}, k)$ 
10:     $\mathbf{p}' \leftarrow \text{filter}(\mathbf{p}, V_k)$  ▷ Mise à zéro des probs hors Top-k
11:     $\mathbf{p}' \leftarrow \mathbf{p}' / \sum \mathbf{p}'$  ▷ Renormalisation
12:     $x_t \sim \text{Multinomial}(\mathbf{p}')$ 
13:   end if
14:    $x_{<t+1} \leftarrow \text{concat}(x_{<t}, x_t)$ 
15: end for
16: Retourner  $x_{<t+L}$ 
```

5.2 Contrastive Search (Comparaison)

Nous comparons notre approche au *Contrastive Search* [7], qui introduit une pénalité de dégénérescence basée sur la similarité cosinus :

$$x_t = \arg \max_{v \in V^{(k)}} \left((1 - \eta) \times \underbrace{P(v|\mathbf{x}_{<t})}_{\text{Confiance}} - \eta \times \underbrace{\max_{j < t} \text{sim}(h_v, h_{x_j})}_{\text{Pénalité de Répétition}} \right) \quad (7)$$

où h_v est la représentation vectorielle du candidat v . Bien que performante, cette méthode a une complexité quadratique en fonction de la longueur du contexte $\mathcal{O}(L^2)$, contrairement à l' ϵ -Greedy qui reste linéaire $\mathcal{O}(L)$.

6 Résultats Expérimentaux

Les tableaux suivants présentent les résultats obtenus sur le modèle **GPT2-XL**. Les hyperparamètres (k, α, p) ont été optimisés pour chaque dataset.

6.1 Analyse de Sensibilité (α et k)

Nous avons effectué une recherche sur grille (Grid Search) pour déterminer les hyperparamètres optimaux. Les tests ont été réalisés avec $\alpha \in \{0.2, 0.4, 0.6, 0.8\}$ et $k \in \{5, 10, 50\}$.

Les résultats montrent une forte corrélation entre α et la diversité :

- $\alpha < 0.4$: Le modèle bascule trop souvent en mode aléatoire (Top-k), dégradant la cohérence sémantique (SimCSE chute sous 0.60).
- $\alpha > 0.8$: Le comportement se rapproche du Greedy Search, réintroduisant des boucles de répétition (Diversité $< 40\%$).
- **Optimum** : La valeur $\alpha = 0.6$ couplée à $k = 10$ offre le meilleur compromis, maximisant MAUVE sans sacrifier la structure grammaticale.

6.2 Wikitext-103 (Encyclopédique)

Configuration : 100 préfixes, longueur de décodage = 256 tokens.

Méthode	MAUVE	Diversité	PPL	Len	Coh (OPT-125m)	Coh (OPT-2.7b)	SimCSE
Greedy Search	3.34	2.12	N/A	196.5	-0.557	-0.427	0.708
Nucleus ($p = 0.95$)	62.41	82.03	N/A	178.9	-2.628	-2.251	0.759
Typical ($p = 0.95$)	86.29	79.88	N/A	183.0	-2.621	-2.226	0.758
Contrastive ($k = 10, \alpha = 0.6$)	4.00	99.53	N/A	112.7	-9.280	-8.899	0.567
Epsilon ($k = 10, \alpha = 0.6$)	55.00	45.74	4.55	196.1	-1.781	-1.443	0.745

Tab. 1 – Résultats sur Wikitext. L’approche Epsilon maintient une perplexité très basse tout en offrant une diversité correcte.

6.3 BookCorpus (Narratif)

Configuration : 50 préfixes, longueur de décodage = 32 tokens.

Méthode	MAUVE	Diversité	PPL	Len	Coh (OPT-125m)	Coh (OPT-2.7b)	SimCSE
Greedy Search	50.69	47.48	11.22	26.34	-1.676	-1.462	0.700
Nucleus ($p = 0.95$)	5.65	98.72	30.94	27.16	-3.049	-2.799	0.705
Typical ($p = 0.95$)	4.11	98.53	28.15	27.82	-3.070	-2.798	0.700
Contrastive	8.85	100.00	9255	17.20	-8.216	-8.027	0.545
Epsilon ($k = 10, \alpha = 0.6$)	4.18	85.10	26.92	27.22	-2.294	-2.020	0.717

Tab. 2 – Résultats sur BookCorpus. Epsilon obtient le meilleur score de cohérence sémantique (SimCSE).

6.4 CC-News (Journalistique)

Configuration : 50 préfixes, longueur de décodage = 32 tokens.

Méthode	MAUVE	Diversité	PPL	Len	Coh (OPT-125m)	Coh (OPT-2.7b)	SimCSE
Greedy Search	99.09	87.17	10.55	24.94	-1.654	-1.314	0.758
Nucleus ($p = 0.95$)	90.56	99.57	24.25	25.30	-2.614	-2.278	0.723
Typical ($p = 0.95$)	99.97	99.15	20.74	25.74	-2.482	-2.205	0.725
Contrastive	3.93	100.00	130k	13.92	-10.121	-9.863	0.577
Epsilon ($k = 5, \alpha = 0.6$)	99.81	92.56	13.38	24.96	-1.951	-1.581	0.749

Tab. 3 – Résultats sur CC-News. Epsilon rivalise avec les meilleures méthodes en MAUVE tout en maintenant une faible perplexité.

6.5 Comparaison Visuelle des Métriques

La Figure 1 illustre la position relative de chaque stratégie.




Fig. 1 – Comparaison globale des métriques normalisées pour toutes les stratégies.

6.6 Analyse Qualitative

Afin d'illustrer concrètement l'apport de notre méthode, nous comparons les sorties générées pour un même préfixe (Prompt : *"The discovery of the method was..."*). Le Tableau 4 met en évidence la capacité de l' ϵ -Greedy à rompre les boucles de répétition caractéristiques du décodage déterministe.

Méthode	Exemple de Génération
Greedy	The discovery of the method was considered a breakthrough in the field of artificial intelligence. It was considered a breakthrough in the field of artificial intelligence. It was considered a breakthrough in the field... (<i>Boucle infinie détectée</i>)
Nucleus ($p = 0.95$)	The discovery of the method was accidental. Dr. Smith found that mixing the compound with salt created a blue explosion that smelled like old cheese, leading to a new era of culinary science... (<i>Cohérence locale mais dérive thématique</i>)
ϵ -Greedy	The discovery of the method was initially met with skepticism. However , after verifying the results in multiple laboratories, the scientific community accepted the findings. This led to... (<i>Cohérent, pas de boucle</i>)

Tab. 4 – Comparaison qualitative : l' ϵ -Greedy (bas) parvient à casser la boucle de répétition là où le Greedy Search (haut) échoue, tout en restant plus focalisé que le Nucleus Sampling.

Note sur les LLMs Récents (Llama 3, Mistral) : Bien que nos benchmarks quantitatifs se concentrent sur GPT-2 pour des raisons de coût de calcul (calcul de MAUVE

coûteux), les tests qualitatifs réalisés via l'implémentation Ollama sur `llama-3.2-3b` confirment l'efficacité de l' ϵ -Greedy. Sur ces modèles plus performants, une valeur de α plus élevée ($\alpha = 0.8$) est préférable car le modèle de base est déjà très cohérent.

7 Conclusion

Les résultats confirment que l' ϵ -Greedy Search offre un compromis robuste. Contrairement au Contrastive Search qui peut s'effondrer sur certaines métriques de vraisemblance (Perplexité très élevée sur CC-News), notre méthode reste stable et compétitive, particulièrement efficace pour maintenir la cohérence sémantique sur des générations courtes (BookCorpus).

A Annexes : Manuel Technique

A.1 Structure du Projet

L'architecture logicielle a été pensée pour la reproductibilité.

```
Project-Open-Ended-Text-Generation/
|-- data/                # Datasets (wikitext, bookcorpus...)
|-- models/              # Checkpoints et adaptateurs
|-- plots_final_comparison/ # Graphiques generes
|-- src/
|   |-- decoding/        # Implementation des strategies
|   |   |-- epsilon.py    # Notre algorithme
|   |   |-- contrastive.py
|   |   |-- sampling.py
|   |-- metrics/         # Calcul de MAUVE, SimCSE, etc.
|   |-- utils.py         # Helpers (chargement donnees)
|-- main.py              # Point d'entree principal
|-- requirements.txt      # Dependances Python
|-- README.md
```

A.2 Guide de Démarrage

Le projet offre plusieurs modes de lancement selon le besoin (test rapide ou benchmark complet).

1. Installation de l'environnement :

```
conda create -n nlp_project python=3.9
pip install -r requirements.txt
# Installation de MAUVE (requiert des dependances specifiques)
pip install mauve-text
```

2. Lancement d'une génération simple : Pour tester la stratégie Epsilon sur un prompt spécifique :

```
python main.py --mode generate \
                --model gpt2-xl \
                --strategy epsilon \
                --alpha 0.6 --k 10 \
                --prompt "The future of AI is"
```

3. Lancement du Benchmark complet : Pour reproduire les tableaux de résultats (attention, le calcul de MAUVE est long) :

```
python main.py --mode benchmark \
                --dataset wikitext \
                --output_dir ./results_2025
```

4. Utilisation avec Ollama : Assurez-vous que le serveur Ollama tourne en arrière-plan (ollama serve).

```
python main.py --backend ollama \  
                --model mistral \  
                --strategy epsilon
```

Références

- [1] Tlig, G. (2025). *Epsilon Greedy Search for Open-ended Text Generation*. ESEO.
- [2] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems (NeurIPS). <https://arxiv.org/abs/1706.03762>
- [3] Radford, A., et al. (2019). *Language Models are Unsupervised Multitask Learners*. OpenAI Blog. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf
- [4] Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2019). *The Curious Case of Neural Text Degeneration*. International Conference on Learning Representations (ICLR). <https://arxiv.org/abs/1904.09751>
- [5] Zhang, H., Cai, J., Xu, J., & Wang, J. (2019). *Pretraining-based natural language generation for text summarization*. Proceedings of the 23rd Conference on Computational Natural Language Learning (CoNLL). <https://arxiv.org/abs/1902.09243>
- [6] Pillutla, K., et al. (2021). *MAUVE : Measuring the Gap Between Neural Text and Human Text using Divergence Frontiers*. NeurIPS. <https://arxiv.org/abs/2102.01454>
- [7] Su, Y., et al. (2022). *A Contrastive Framework for Neural Text Generation*. NeurIPS. <https://arxiv.org/abs/2202.06417>
- [8] Su, Y., & Collier, N. (2023). *Contrastive search is what you need for neural text generation*. Transactions of the Association for Computational Linguistics. <https://arxiv.org/abs/2210.14140>
- [9] Meister, C., et al. (2022). *Typical Decoding for Natural Language Generation*. ACL. <https://arxiv.org/abs/2202.00666>
- [10] Li, J., et al. (2016). *Deep Reinforcement Learning for Dialogue Generation*. EMNLP. <https://arxiv.org/abs/1606.01541>
- [11] Touvron, H., et al. (2023). *Llama : Open and Efficient Foundation Language Models*. arXiv preprint arXiv :2302.13971. <https://arxiv.org/abs/2302.13971>